


Macroproceso**Proceso****Título: Formato de registro de trabajo de grado****UNIVERSIDAD
NACIONAL
DE COLOMBIA**

Programa Curricular

Administración de Sistemas
Informáticos

Fecha

10

7

2025

Datos del estudiante

Nombres: Santiago

Apellidos: Mazo Orozco

Tipo de identificación:

T.I.

C.C.

X

C.
E.

Número: 1004755636

Correo institucional:smazoo@unal.edu.co

Teléfono:3205271200

Formulación Trabajo de Grado**1. MODALIDAD/SUBMODALIDAD DE TRABAJO DE GRADO**

- Trabajos investigativos/Proyecto Final

2. TÍTULO DEL TRABAJO DE GRADO

Eficiencia y Sostenibilidad Computacional de Algoritmos de Machine Learning para la clasificación supervisada en Analítica de Datos: Un Enfoque Multiagente


3. INTRODUCCIÓN Y JUSTIFICACIÓN

En la actualidad, el crecimiento exponencial de los datos generados por sensores, plataformas digitales, redes sociales y sistemas corporativos ha sobrepasado la capacidad de las soluciones tradicionales de procesamiento, revelando limitaciones en escalabilidad, tolerancia a fallos y capacidad adaptativa. Este contexto plantea nuevos desafíos para el análisis eficiente de la información, especialmente en el ámbito del Machine Learning (ML), donde los algoritmos deben evaluarse no solo por su precisión, sino también por su eficiencia computacional y sostenibilidad energética.

Los Sistemas Multiagente (SMA) emergen como una alternativa poderosa para enfrentar esta complejidad. Su arquitectura descentralizada, la autonomía de sus agentes, su capacidad de comunicación y su proactividad los convierten en herramientas versátiles para operar en entornos dinámicos y distribuidos. Esta investigación propone el uso de SMA como plataforma experimental para evaluar de forma controlada diversos algoritmos de ML, con énfasis en métricas clave de eficiencia y sostenibilidad.

Esta propuesta se enfocará en un subconjunto representativo y contrastado, por ejemplo, algoritmos de Machine Learning supervisado de clasificación como Random Forest y Support Vector Machine, en fases específicas del ciclo de vida (como entrenamiento o inferencia, según el caso). Para ello, cada agente del sistema se especializará en una tarea del proceso, como la recolección de datos, el preprocesamiento, el entrenamiento del modelo, la evaluación de desempeño o la recolección de métricas. Esta distribución modular permite diseñar experimentos replicables, facilitar cambios en los algoritmos o condiciones, y obtener mediciones homogéneas bajo escenarios equivalentes.

La evaluación se centrará en métricas computacionales concretas como el tiempo de ejecución (en milisegundos), el rendimiento del sistema (throughput), el uso promedio de CPU y memoria, y el consumo energético (normalizado por MB procesado). Para garantizar validez estadística, cada experimento se repetirá al menos diez veces bajo condiciones controladas, tanto en un sistema tradicional (grupo de control) como en la arquitectura basada en SMA (grupo de tratamiento). La medición se realizará mediante herramientas de monitoreo como JConsole o



Prometheus, y los resultados se analizarán con pruebas estadísticas inferenciales (por ejemplo, $t_{test} < 0.05$).

Este enfoque experimental busca llenar un vacío identificado en la literatura: la ausencia de arquitecturas SMA generalizables que integren de manera sistemática todas las fases del procesamiento y evaluación de algoritmos de ML, considerando además la sostenibilidad computacional. Aunque existen investigaciones que han aplicado SMA a contextos específicos —como la clasificación de licitaciones (Kuzin et al., 2022), minería de datos distribuida (Braubach y Pokahr, 2019), o planificación en ciudades inteligentes (Paik, 2024)— ninguna de ellas integra simultáneamente criterios de eficiencia, adaptabilidad y sostenibilidad energética en un marco experimental homogéneo.

La implementación de este enfoque, sin embargo, no está exenta de retos. Entre ellos destacan la complejidad del diseño y coordinación de los SMA, la necesidad de datos estructurados y gobernados, y la gestión ética del procesamiento algorítmico. También se reconocen preocupaciones como la privacidad de los datos, la dependencia tecnológica y el impacto ambiental del uso intensivo de recursos computacionales. Por tanto, se promueve un enfoque responsable que contemple principios como el “control humano significativo” y el “diseño ético por defecto”, asegurando que la tecnología se utilice de manera consciente y alineada con el bienestar colectivo.

En síntesis, esta propuesta busca demostrar que los SMA no solo son útiles como arquitectura de procesamiento distribuido, sino también como herramienta científica para evaluar de forma rigurosa y sostenible algoritmos de ML en entornos simulados, homogéneos y controlados.

4. OBJETIVO GENERAL

Diseñar e implementar un prototipo de arquitectura basada en Sistemas Multiagente (SMA) para evaluar la eficiencia computacional y la sostenibilidad energética durante el entrenamiento de algoritmos de Machine Learning supervisado de clasificación, en entornos simulados de analítica de datos.

5. OBJETIVOS ESPECÍFICOS

1. Modelar la arquitectura de un prototipo de Sistema Multiagente (SMA) capaz de orquestar y gestionar fases clave del pipeline de Machine Learning (ML) supervisado de clasificación, incluyendo la ingesta, el preprocesamiento y la preparación de datos para el entrenamiento, en entornos simulados de analítica de datos.
2. Implementar el prototipo de arquitectura SMA modelado, integrando al menos dos algoritmos representativos de ML supervisado de clasificación (por ejemplo, Random Forest y Support Vector Machine), para su ejecución durante la fase de entrenamiento, utilizando la plataforma JADE como entorno de gestión multiagente.
3. Evaluar la eficiencia computacional y la sostenibilidad energética del prototipo SMA frente a una arquitectura centralizada tradicional, durante la fase de entrenamiento de los algoritmos seleccionados, mediante la medición de métricas como tiempo de ejecución, throughput, uso promedio de CPU y memoria, y consumo energético (normalizado en Joules por MB procesado) en escenarios simulados, controlados y replicables.
4. Analizar e interpretar los resultados obtenidos de la evaluación cuantitativa, para validar la eficiencia y sostenibilidad del SMA, y sintetizar las principales implicaciones técnicas, éticas y operativas de su adopción en entornos de analítica de datos, identificando desafíos, limitaciones y oportunidades de mejora.

6. ANTECEDENTES

El Grupo de Investigación en Ambientes Inteligentes Adaptativos GAIA, en alianza con el Grupo de investigación ACSIC de la Universidad de Baleares ha incursionado en Green Computer, específicamente en los consumos generados por los algoritmos de inteligencia artificial y recientemente fue aprobada la ejecución de un Proyecto Internacional con la financiación de la Universidad española.

Los Sistemas Multiagente (SMA) han emergido como una solución prometedora en diversos campos debido a su diseño descentralizado y su capacidad para que múltiples agentes inteligentes operen de manera autónoma y colaborativa. Estos sistemas son especialmente aptos para entornos dinámicos y complejos, lo que los hace relevantes para la analítica de grandes volúmenes de datos. Por ejemplo, en el ámbito de la gestión del riego agrícola, se ha demostrado que los modelos basados en agentes inteligentes pueden mejorar la eficiencia en el uso del agua al integrar inteligencia artificial, sistemas multiagente e internet de las cosas en el riego de precisión.



Rodríguez et al. (2024) presentan una revisión sistemática de herramientas y protocolos para medir consumo energético de modelos ML durante entrenamiento e inferencia, con comparaciones cualitativas y cuantitativas sobre tareas de visión y lenguaje. Un recurso reciente que mide el consumo energético de inferencia en servicios de IA generativa, demostrando que se pueden lograr ahorros de más del **40 % sin sacrificar funcionalidad mediante ajustes inteligentes (Chung et al., 2025). Yu et al.(2022) realizan estudio cuyo objetivo es explorar y comparar los niveles de eficiencia energética de los algoritmos de aprendizaje automático más utilizados -los algoritmos de regresión logística (LR), k-nearest neighbor, support vector machine, random forest (RF) y extreme gradient boosting (XGB), así como cuatro variantes diferentes de algoritmos de redes neuronales (NN)- cuando se aplican a conjuntos de datos de laboratorios clínicos.


Esta propuesta se orienta a retomar algunos enfoques para construir una plataforma SMA experimental que: modulariza tareas (preprocesamiento, entrenamiento, evaluación, monitoreo de métricas), evalúa múltiples modelos ML midiendo CPU, memoria, throughput, tiempo de ejecución y consumo eléctrico; implementa métricas estandarizadas como Energy Efficiency Ratio, lifecycle emissions y environmental impact, basadas en frameworks existentes; establece escenarios homogéneos y replicables para comparaciones rigurosas y genera evidencia empírica sobre cómo los SMA facilitan la eficiencia energética en entornos de ML distribuido.

La presente propuesta busca aprovechar un vacío en la literatura al aplicar agentes que permitan realizar evaluación integrada de eficiencia y sostenibilidad de modelos de ML en etapas completas del pipeline de analítica de datos.

En cuanto a las métricas de sostenibilidad, el estudio se enfocará en la cuantificación directa del consumo de recursos computacionales durante el entrenamiento de los algoritmos de Machine Learning. Para ello, se utilizará la métrica de Joules por MB procesado, basándose en metodologías de cálculo de eficiencia energética. La energía consumida se estimará a partir de la potencia promedio del CPU (en vatios) y el tiempo de ejecución (en segundos). Esta aproximación busca evaluar el impacto energético de los sistemas, considerando su relevancia en el contexto de la sostenibilidad tecnológica. Cabe señalar que, si bien la propuesta contempla métricas estandarizadas más amplias como 'emisiones del ciclo de vida' e 'impacto ambiental', las fuentes no detallan explícitamente los frameworks específicos para su cuantificación directa en la metodología del estudio. Sin embargo, el componente cualitativo de la investigación sí abordará una reflexión profunda sobre las implicaciones ambientales, éticas y regulatorias de la Inteligencia Artificial y los centros de datos

7. METODOLOGÍA

- **Enfoque Metodológico:** Este estudio adoptará un enfoque metodológico puro, con una primacía cuantitativa complementada por una dimensión cualitativa, para abordar de manera integral el enfoque de los Sistemas Multiagente (SMA).
- El componente cuantitativo se centrará en la recolección y análisis de datos numéricos para probar la hipótesis principal y establecer relaciones causales, buscando resultados cuantificables que permitan la generalización y comparación. Para ello, se clasificará como investigación aplicada, ya que busca generar una solución práctica y funcional. Adoptará un diseño experimental puro o cuasiexperimental para evaluar el efecto de la arquitectura multiagente sobre las variables dependientes bajo condiciones controladas o equivalentes. El objetivo es determinar el consumo de los algoritmos de Machine Learning en términos de tiempo y recursos bajo condiciones equivalentes .
- El componente cualitativo será esencial para una comprensión integral de las profundas transformaciones y las implicaciones éticas y contextuales de la adopción de SMA. Este enfoque cualitativo interpretativo se realizará a través del análisis documental para examinar críticamente la eficacia, los desafíos y el contexto de implementación de los SMA, priorizando significados, dilemas y contextos sociotécnicos. Se buscará comprender cómo los actores construyen significados sobre fenómenos complejos, reconociendo que los datos están cargados de implicaciones sociales, culturales y organizacionales. Esto incluye la identificación de categorías clave, significados, dilemas y contextos sociotécnicos en la implementación de SMA, así como la evolución conceptual y tecnológica de la IA distribuida. El análisis de contenido temático será la técnica principal para identificar patrones discursivos, tensiones conceptuales y significados emergentes a partir de documentos académicos, industriales y regulatorios. Es importante señalar que en el enfoque cualitativo no se prueban hipótesis que se establezcan previamente, sino que estas se desarrollan a lo largo del propio trabajo conforme se recolecta la información. Además, no se basa en la estadística, sino en un análisis del discurso, y sus resultados no pueden generalizarse, ya que examina realidades subjetivas donde cada persona o sociedad visualiza la realidad de forma distinta, siendo necesaria la interpretación de esa realidad.
- **Operacionalización de Variables:** A continuación, se detalla la operacionalización de variables para permitir su medición




cuantitativa:

- Variable Independiente:
 - Arquitectura centralizada (grupo de control).
 - Sistema Multiagente (SMA) (grupo de tratamiento). Ambos sistemas serán evaluados bajo condiciones equivalentes para medir el efecto del tipo de arquitectura sobre las variables dependientes, generando escenarios de prueba controlados.
- Variables Dependientes:
 - Eficiencia del procesamiento de datos: Se medirá a través de:
 - Tiempo total de ejecución (en milisegundos).
 - Rendimiento del sistema (throughput) (en registros por milisegundo).
 - Uso promedio de CPU (en porcentaje).
 - Uso de memoria (en MB).
 - Eficiencia por unidad de carga: Se evaluará la cantidad de datos correctamente procesados por segundo y por porcentaje de uso de CPU.
 - Eficiencia por consumo de memoria: Se analizarán los datos procesados por MB utilizado
- Eficiencia Energética (Green Computing): Se evaluará el consumo energético. Esta dimensión es relevante para la sostenibilidad tecnológica y aborda el impacto ambiental asociado al uso de recursos informáticos intensivos. Se estimará el consumo energético (Joules por MB procesado), calculándolo a partir del consumo promedio de CPU (en vatios) y el tiempo de ejecución (en segundos), normalizándolo por unidad de datos procesados.
- Adaptabilidad y Resiliencia: Se evaluará cómo los sistemas multiagente (SMA) reaccionan ante cambios y fallos, ya que una de sus características más poderosas es su capacidad de adaptarse en tiempo real y ser más resistentes a fallos individuales. Los SMA, al ser flexibles, permiten el intercambio de módulos o comportamientos, facilitando la evaluación de diferentes algoritmos o tareas. Las métricas incluyen:
 - Tiempo de respuesta ante eventos dinámicos (en segundos).
 - Tasa de éxito en reconfiguración autónoma (en porcentaje).
 - Número de fallos recuperados automáticamente
 - Eficiencia adaptativa: Se calculará el tiempo promedio de recuperación tras un fallo dividido por la cantidad de eventos adaptativos resueltos
- Escalabilidad: Se medirá la capacidad del sistema para mantener sus métricas de eficiencia y rendimiento ante incrementos significativos en el volumen de datos. Los SMA son inherentemente flexibles y escalables, adaptándose a entornos cambiantes mediante la adición o modificación de agentes.

8. CRONOGRAMA DE ACTIVIDADES


ACTIVIDADES A REALIZAR	Semanas de ejecución de cada actividad															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Actividad 1: Revisión de Literatura y Definición de Metodología.	X	X	X													
Actividad 2: Diseño de la Arquitectura del SMA y del Experimento.		X	X	X	X											
Actividad 3: Implementación y Desarrollo de Prototipos.				X	X	X	X	X								
Actividad 4: Recolección y Pre-procesamiento de Datos Experimentales.							X	X	X	X						
Actividad 5: Análisis e Interpretación de Datos.									X	X	X	X	X			



República Bolivariana de Venezuela										Ministerio del Poder Popular para el Proceso Comunal										Escuela Bolivariana de Educación Superior "Simón Bolívar"										Instituto de Investigación y Desarrollo Científico y Tecnológico									
Actividad 6: Visualización de Hallazgos y Elaboración de Modelos.																																							
Actividad 7: Redacción del Reporte de Resultados.																																							
Actividad 8: Consolidación de Conclusiones, Implicaciones y Trabajos Futuros.																																							

9. RESULTADOS ESPERADOS Y APOORTE ESPECÍFICO

- Desarrollo e Implementación de Prototipos de Software:
 - Herramienta basada en agentes inteligentes para evaluación de desempeño
 - Una versión funcional de la plataforma.
 - Un prototipo multiagente que valide el modelo propuesto, incluyendo pruebas de desempeño cualitativo y cuantitativo.
 - En caso de enfoques específicos un prototipo Multiagente desarrollado en la plataforma JADE para agilizar y automatizar los experimentos de evaluación de la eficiencia computacional y la sostenibilidad energética de algoritmos de Machine Learning, sirviendo como una plataforma experimental modular y replicable para la analítica de datos.
 - La arquitectura completa del SMA propuesta, con la descripción de sus agentes y sus interacciones.
- Evidencia de Datos y Análisis:
 - Archivos de datos brutos (.csv) y scripts de Python utilizados para el procesamiento y análisis estadístico, asegurando la transparencia y replicabilidad.
 - Gráficos comparativos (barras y líneas) generados en Python y Excel que ilustren las diferencias de desempeño entre las arquitecturas.
 - Resultados empíricos detallados sobre la eficiencia (ej., tiempo de ejecución, rendimiento, consumo de recursos) y la adaptabilidad del SMA en comparación con modelos tradicionales.
 - Análisis temático cualitativo que identifique categorías clave, significados, dilemas y contextos sociotécnicos en la implementación de SMAs.
 - Modelos teóricos o conceptuales emergentes que describan patrones, tendencias y las interrelaciones entre categorías.
 - Informes de validación y verificación de modelos (ej. grafos de alcanzabilidad, reportes estándar) que demuestren la solidez del diseño.
- Documentación de la Investigación:
 - Documentación detallada del procedimiento experimental y la metodología empleada.
 - Capturas de pantalla o evidencia visual de la ejecución del sistema.
 - Un reporte de resultados cualitativos que se caracterice por una exposición narrativa detallada, vívida y natural, empleando un estilo más personal y redactado en tiempo pasado. Se soportarán las categorías y temas emergentes con ejemplos concretos, incluyendo fragmentos de contenido o citas directas de las fuentes documentales, utilizando su lenguaje original para enriquecer la narración. Se recomendará el uso de ejemplos, anécdotas, metáforas y analogías para enriquecer la descripción. La presentación de los hallazgos incluirá elementos gráficos como modelos, tipologías, taxonomías, diagramas, tablas y matrices, para organizar y transmitir los resultados de manera efectiva. Además, se asegurará una triangulación de datos y fuentes cuando sea posible para establecer la dependencia y credibilidad de la investigación
 - Una discusión de las limitaciones del estudio y sugerencias para futuras investigaciones. Esta sección incluirá una reflexión crítica sobre cómo la calidad, fuentes o tipos de datos, o el proceso analítico, pudieron haber influido en los resultados. Se discutirán posibles sesgos en la recolección o análisis de datos. Se considerarán las implicaciones para futuras investigaciones, políticas o prácticas, y se identificarán los dilemas o desafíos éticos encontrados, proponiendo sugerencias para futuros investigadores
- Aporte Específico (Uso y Beneficios de los Resultados) Los resultados de la investigación contribuirán significativamente en varios



niveles:

- Avance del Conocimiento y la Metodología:
- Llenar un vacío en la literatura al proporcionar evidencia empírica y generalizable sobre la eficacia de los SMA en la integración de todas las fases del análisis de datos.
- Ofrecer un modelo de control inteligente que integre los paradigmas Holónico y Multiagente, validado con pruebas de desempeño.
- Desarrollar nuevos patrones de ataque o extracción distribuida de datos en ciberseguridad mediante SMAs, o mejorar los métodos existentes de extracción de información en entornos de seguridad.
- Acelerar el ritmo de la innovación al permitir a los investigadores diseñar y llevar a cabo experimentos, analizar datos y formular nuevas hipótesis de manera más eficiente.

● Beneficios Industriales y Empresariales (Industria 4.0):

- Mejorar la eficiencia y la adaptabilidad del procesamiento de datos en entornos complejos y dinámicos, superando las limitaciones de las arquitecturas tradicionales.
- Optimizar los procesos de manufactura, lograr mayor flexibilidad, eficiencia y auto-gestión en fábricas inteligentes.
- Contribuir a la competitividad y supervivencia de Pequeñas y Medianas Empresas (PyMEs) al facilitar la adopción de tecnologías de la Industria 4.0.
- Permitir la consolidación de operaciones de negocio bajo una interfaz unificada basada en agentes de IA, mejorando la eficiencia y la calidad.
- Facilitar la gestión de cadenas de suministro, la optimización de inventarios, la previsión de demandas de clientes y la planificación logística en operaciones comerciales.

● Impacto Social y Ambiental:

- Contribuir a la sostenibilidad tecnológica mediante el análisis de la eficiencia energética de los sistemas multiagente.
- Mejorar la eficiencia en el uso del agua en la agricultura mediante modelos de agentes inteligentes, apoyando la sostenibilidad agrícola y la seguridad alimentaria.
- Potencialmente asistir en la predicción y prevención de enfermedades (ej. cáncer, epidemias) a través del análisis genético y la gestión de grandes conjuntos de datos.

● Consideraciones Éticas y Regulatorias:

- Proporcionar evidencia para la reflexión regulatoria y filosófica sobre la autonomía de los Sistemas Multiagente (SMA) y la imperativa necesidad de un control humano significativo. Se abordará la tensión conceptual entre la autonomía técnica de los SMA y la indispensable supervisión institucional, reconociendo que estos sistemas han evolucionado de herramientas funcionales a fenómenos sociotécnicos que exigen una profunda reflexión regulatoria y filosófica.
- Informar el debate sobre la ética de la IA y sus implicaciones, con un enfoque particular en la prevención de sesgos algorítmicos y la responsabilidad humana en la toma de decisiones críticas. Se destacará el riesgo que implica delegar decisiones críticas a sistemas autónomos, como los Sistemas de Armas Autónomas Letales (LAWS), y se enfatizarán principios como el "control humano significativo" y el "diseño ético por defecto". Además, se analizarán los hallazgos de estudios que demuestran que los sistemas de IA pueden producir resultados discriminatorios y erróneos, como las diferencias en las tasas de error en el reconocimiento facial basadas en género y color de piel. Se contribuirá a un desarrollo más consciente y responsable de la tecnología, incluyendo la consideración del impacto ambiental de la IA y los centros de datos, así como la necesidad de marcos regulatorios y éticos claros y una supervisión humana continua.

10. BIBLIOGRAFÍA CITADA


- Braubach, L., & Pokahr, A. (2019). ActoData: A multi-agent architecture for data analytics. Multiagent and Grid Systems, 15(3), 199–220.



- Chung Jae-Won and Jiachen Liu and Jeff J. Ma and Ruofan Wu and Oh Jun Kwon and Yuxuan Xia and Zhiyu Wu and Mosharaf Chowdhury. (2025). he ML.ENERGY Benchmark: Toward Automated Inference Energy Measurement and Optimization. Arxiv, preprint.
- Kuzin, A., Ivanov, D., & Petrova, M. (2022). Multi-agent systems for tender classification. Journal of Intelligent Systems, 31(2), 123–137.
- Paik, H. (2024). Smart city infrastructure: A multi-agent perspective. International Journal of Urban Computing, 12(1), 45–59.
- Rodriguez C., Laura Degioanni, Laetitia Kameni and Richard Vidal and Giovanni Neglia (2024). Evaluating the Energy Consumption of Machine Learning: Systematic Literature Review and Experiments. Eprint.
- Yu JR, Chen CH, Huang TW, Lu JJ, Chung CR, Lin TW, Wu MH, Tseng YJ, Wang HY. Energy Efficiency of Inference Algorithms for Clinical Laboratory Data Sets: Green Artificial Intelligence Study. J Med Internet Res. 2022 Jan 25;24(1):e28036. doi: 10.2196/28036. PMID: 35076405; PMCID: PMC8826151.

11. REFERENCIAS BIBLIOGRÁFICAS ADICIONALES

- De Grande, P., & Eguía, M. (2007). Modelos y teorías. Sistemas multiagente y mercado de trabajo. 8° Congreso Nacional de Estudios del Trabajo (ASET), Buenos Aires. (Útil para entender la construcción de modelos multiagente).
- Focalx. (s.f.). La IA en los Sistemas Multiagente: Cómo interactúan y colaboran los agentes de IA. (Ofrece una visión general de la interacción y colaboración de agentes de IA).
- González Pérez, J. L., & Martínez Miranda, M. A. (2018). Uso de sistemas multiagentes para el aprendizaje automático. Ciencia e Ingeniería, 19(2), 239-247. (Directamente relevante para el uso de SMA en Machine Learning).
- IBM. (s.f.). ¿Qué es un sistema multiagente?. (Proporciona una definición y distinción entre sistemas monoagente y multiagente).
- IEBS Business School. (2024). Qué son los agentes de IA y los sistemas multiagente. (Destaca los SMA como una innovación prometedora en GenAI para el sector empresarial).
- KPMG. (s.f.). La IA multiagente revoluciona las operaciones de negocio. KPMG Tendencias. (Ofrece una perspectiva de la industria sobre los beneficios de los SMA en operaciones de negocio).
- Portal ERP Colombia. (s.f.). Los sistemas multiagente están dando forma al futuro de la IA. (Visión sobre el impacto futuro de los SMA en la IA).
- Red Hat. (2024). ¿Qué es la inteligencia artificial con agentes?. (Explica cómo la IA con agentes puede iniciar acciones y su relación con RAG).
- Wooldridge, M. (2009). An Introduction to MultiAgent Systems. John Wiley & Sons Ltd. (Texto introductorio y fundamental en sistemas multiagente).
- Bechara, A., Damasio, A. R., Tranel, D., & Damasio, H. (1997). Deciding advantageously before knowing the outcome: Neural correlates of somatic markers. Science, 275(5304), 129–132.
- Damasio, A. R. (1996). Descartes' error: Emotion, reason, and the human brain. Avon Books.
- Damasio, A. R. (1999). The feeling of what happens: Body and emotion in the making of consciousness. Harcourt Brace.
- Ekman, P. (1971). Universals and cultural differences in facial expressions of emotion. Nebraska Symposium on Motivation, 19, 207–283.
- Hodge, M. (2008). The interface between psychology and religion. Routledge.
- Lucy, J. A. (1996). Language diversity and thought: A cognitive linguistic approach. Cambridge University Press.
- Markus, H. R., & Kitayama, S. (1991). Culture and the self: Implications for cognition, emotion, and motivation. Psychological Review, 98(2), 224–253.
- Rogoff, B. (1990). Apprenticeship in thinking: Cognitive development in social context. Oxford University Press.
- Vargas, E. (2022, enero 28). Trabajos académicos: citas y referencias bibliográficas. Acento. Recuperado de <https://acento.com.do/opinion/trabajos-academicos-citas-y-referencias-bibliograficas-9027747.html>
- Patel et al. (2023). Next Generation of Multi-Agent Driven Smart City Applications and Research Paradigms. IEEE Access (IEEE) – Indexada en Scopus y Web of Science.

Macroproceso**Proceso****Título: Formato de registro de trabajo de grado**

UNIVERSIDAD
NACIONAL
DE COLOMBIA

Aval del futuro director			
Nombre:	Néstor Darío Duque M	Unidad Académica Básica:	Depto Informática y Computación
Correo electrónico:	ndduqueme@unal.edu.co	Teléfono:	3007876574
Firma:	 <i>Nota: con la firma el profesor manifiesta que participó en la construcción de la propuesta y avala su presentación. Además, se compromete a realizar el proceso de acompañamiento durante el período académico inmediatamente siguiente.</i>		

Firma del estudiante